



Санкт-Петербургский государственный университет
Кафедра системного программирования

Динамическая бинарная трансляция в RISC-V с помощью Instrew

Михайлов Илья Игоревич, группа 21.Б07-мм

Научный руководитель: Д.С. Косарев, ассистент кафедры системного программирования

Санкт-Петербург
2024

- Бинарные трансляторы являются инструментами для анализа кода, профилиции и эмуляции
- Важным классом которых являются динамические бинарные трансляторы (далее — ДБТ)
- В качестве промежуточного представления для ДБТ хорошо использовать LLVM IR
 - ▶ Тулчейн LLVM позволяет проводить качественные оптимизации
- Хотим ДБТ для RISC-V

- Динамические бинарные трансляторы:
 - ▶ QEMU
 - ▶ Box64
 - ▶ Rosetta 2
 - ▶ Valgrind
- Динамические бинарные трансляторы с поднятием в LLVM IR:
 - ▶ McSema + Remill¹
 - ▶ Instrew + Rellume
 - ▶ DBILL, HQEMU
- Выводы:
 - ▶ Instrew работает быстрее, чем QEMU и Valgrind, а так же имеет API для добавления инструментов бинарного анализа²
 - ▶ Из всех рассмотренных ДБТ с поднятием в LLVM IR Instrew + Rellume поддерживается контрибьютором и уже имеет guest-поддержку RISC-V

¹https://se.math.spbu.ru/thesis/texts/Frolov_Timofej_Sergeevich_Spring_practice_2nd

²<https://mediatum.ub.tum.de/doc/1614897/1614897.pdf>

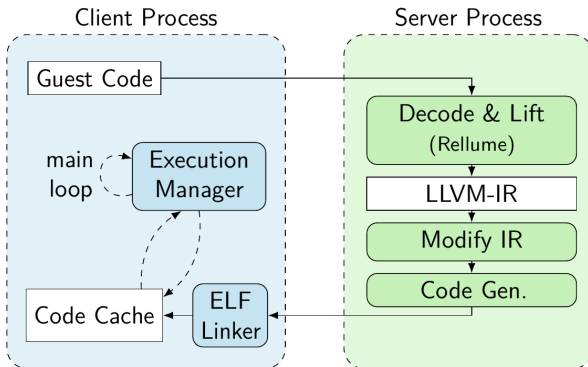
Постановка задачи

Цель: Добавить поддержку host-архитектуры RISC-V для ДБТ Instrew

Задачи:

- ❶ Выполнить обзор архитектуры Instrew
- ❷ Реализовать минимальную функциональность для запуска Instrew на RISC-V:
 - ▶ Скомпилировать, добавив процессорно-специфические патчи и поставив константы
 - ▶ Реализовать функции, связанные с RISC-V ABI
- ❸ Протестировать на простых программах

Архитектура Instrew



3

- В данной практике была проведена работа над клиентом Instrew

³<https://mediatum.ub.tum.de/doc/1614897/1614897.pdf>

Реализация (1/2)

- Чтобы скомпилировать, необходимо:
 - ▶ Проставить константы
 - ▶ Сделать простой header на ассемблере для входа в программу, после `exesve`
- Оказалось, что не все псевдоинструкции описаны в документации RISC-V⁴

⁴<https://reviews.llvm.org/D49661>

Особенности Instrew

- Флаги сборки клиента Instrew:
 - ▶ Клиент во время запуска выдаёт ошибку сегментации
 - ▶ Утилита `rtar` показывает, что к клиенту динамически линкуется `ld-linux` и выполнить релокации невозможно
 - ▶ Оказалось, что `-static-pie` флаг у `gcc-13` на `x86_64` и RISC-V отличается семантикой
- Динамические релокации:
 - ▶ Так как `instrew-client` собирается и линкуется без `libc`, ему нужно самому обработать свои релокации
 - ▶ Клиент загадочно падает на какой-то релокации
 - ▶ Оказалось, что над объявлением функции `memset` стоит атрибут `weak` и из-за этого нужно реализовывать другую релокацию
- Некоторый вывод:
 - ▶ Из-за специфических флагов сборки и линковки сложно диагностировать ошибки сегментации
 - ▶ `Asan` и `gprof` здесь не работают, `Valgrind` не помог
 - ▶ Остается только `printf`, `gdb`

Реализация (2/2)

- После успешного запуска клиента Instrew нужно:
 - ▶ Реализовать эмуляцию системных вызовов для RISC-V
 - ▶ Проставить джампы в PLT таблице
 - ▶ Реализовать некоторые релокации для запуска просто примера
- Оказалось, что:
 - ▶ Сервер запускает клиент Instrew через fork и fexecve
 - ★ Возникли сложности с диагностированием с помощью gdb
 - ★ follow-exec-mode не работал
 - ★ Отдельно запуская клиент в gdb, не подгружались символы
 - ★ Через некоторое время был найден флаг Instrew, который запускал клиент через execve
 - ▶ Диагностировать ошибки непросто:
 - ★ При неправильной подстановке опкода/адреса, нужно диагностировать память с помощью gdb
 - ★ Без RISC-V декодера не обойтись
- Небольшой итог:
 - ▶ Реализовывать эмуляцию системных вызовов и функции RISC-V ABI трудоёмко

- Удалось успешно протестировать:
 - ▶ Программах без libc, исполняющих системные вызовы
 - ▶ Факториале и фибоначчи, выводящих результат в exit code
 - ▶ Факториале с минимальным рантаймом, который выводит результат на экран
- Не удалось протестировать на:
 - ▶ Динамически слинкованных программах и программах использующих libc
 - ▶ Программах, с флагами сборки -pie
 - ▶ Программах, где не конкретная релокация еще не реализована
- Вывод:
 - ▶ Работают статически слинкованные программы, с простым рантаймом и системными вызовами

В результате работы были выполнены следующие задачи:

- 1 Выполнен обзор архитектуры Instrew
- 2 Реализованы процессорно-специфические патчи
- 3 Реализована эмуляция системных вызовов, PLT таблица и минимальный набор ELF релокаций
- 4 Instrew был протестирован на статически линкованных программах, с простым рантаймом